


What we have learned for ML

CHEN Kejie 陈克杰 (chenkj@sustech.edu.cn)

15-Apr-26

What is AI?

人工智能算法（**AI Algorithms**）是通过数学与计算模型，赋予机器感知、推理、学习、决策等类人智能能力的方法与规则集合。其核心目标是让机器能够从数据或环境中自主学习规律，解决复杂问题（如识别图像、理解语言、预测趋势），**而无需依赖显式编程的固定指令**。

$$y = f(x)$$


分类 (Classification)
聚类 (Clustering)
回归 (Regression)

符号学习 (Symbolic Learning)
统计学习 (Statistical Learning)
深度学习 (Deep Learning)

数据预处理(Preprocessing)
数据清洗(Washing)
特征选取(Feature Selection)

What is AI?

1950s-1980s

符号学习(Symbolic Learning):

符号学习是一种基于规则和逻辑推理的人工智能方法，它使用符号(Symbols)代表事物，并通过逻辑规则(Rules) 进行推理和学习。


这些“符号”可以是：

- 数学公式
- 逻辑规则
- 概念、对象、关系（如“猫是动物”）
- 知识库中的实体（如“巴黎是法国的首都”）

常见算法：

决策树(Decision Tree)

原理：基于一系列符号规则
(“如果-那么”)进行分类或回归



1990s-2010s

统计学习(Statistical Learning, Machine Learning):

统计学习是一种基于数据统计和数学建模的机器学习方法，通过从大量数据中学习**统计模式**，以预测未知数据，而不是依赖人工规则(如符号学习)。

核心步骤:

1.收集数据(数据集)

2.构建数学模型(使用概率、统计方法)

3.训练模型(找到数据中的规律)

4.测试模型(在新数据上验证模型效果)

5.预测新数据(泛化能力)

常见算法:

线性回归 (Linear Regression) :





用于预测数值，如房价预测。

逻辑回归 (Logistic Regression) :

用于分类，如垃圾邮件检测。

支持向量机 (SVM) :

用于分类任务，如人脸识别



What is AI?

ARTIFICIAL INTELLIGENCE

IS NOT NEW

ARTIFICIAL INTELLIGENCE

Any technique which enables computers to mimic human behavior



MACHINE LEARNING

AI techniques that give computers the ability to learn without being explicitly programmed to do so



DEEP LEARNING

A subset of ML which make the computation of multi-layer neural networks feasible



1950's

1960's

1970's

1980's


1990's

2000's

2010s

那么如何评价模型好坏?

- **Generalization error**: Error on the test dataset (泛化误差)
- **Empirical error**: Error on the training set, also known as “training error” (经验误差)




- The smaller the generalization error, the better
- Should the empirical error be as small as possible?

NO! Because there will be “overfitting”

How to do AI?


过拟合 (Overfitting): 模型过于复杂, 严格记住训练数据中的细节, 导致泛化能力差, 无法处理新的数据。

欠拟合 (Underfitting): 模型过于简单, 无法学习到训练数据的关键特征, 导致训练集和测试集的表现都很差。




Three key questions:

➤ How to get test results?
(如何获得测试结果)




Assessment method
(评估方法)

➤ How to evaluate the performance?
(如何评估性能优劣)



Performance measurement
(性能度量)

➤ How to judge the substantial
difference?
(如何判断实质差别)



Comparative test
(比较检验)


The key: how to get the “test set”? (怎么获得测试集)

The test set should be "mutually exclusive"
with the training set
训练数据和测试数据互斥

Common methods:

- Hold-out (留出法)
- Cross validation (交叉验证法)
- Bootstrap (自助法)

Hold-out




将数据集分成训练集（**Training set**）和测试集（**Test set**），在训练集上训练模型，在测试集上评估模型的泛化能力。

Note:

- Maintain consistency of data distribution (for example: stratified sampling)
- Repeated division many times (for example: 100 random divisions)
- The test set cannot be too large or too small (for example: $1/5 \sim 1/3$)

How to do AI?

通过多次划分数据集来提高模型性能的稳定性，并减少过拟合风险。




K 值越大一定越好吗？

How to do AI?

Based on “bootstrap sampling” (自助法)

Also known as “sampling with replacement”, “sampling with repeatability”



Approximately 36.8% of the samples did not appear

$$\downarrow \lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m \leftrightarrow \frac{1}{e} \approx 0.368$$

out-of-bag estimation

- The training set is the same size as the original sample set
- Data distribution has changed

Error rate:

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(x_i) \neq y_i)$$

Accuracy:

$$\text{acc}(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(x_i) = y_i) = 1 - E(f; D).$$

指标	公式	解释
错误率 (Error Rate)	$E(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(x_i) \neq y_i)$	预测错误的样本占比，越小越好
准确率 (Accuracy)	$\text{acc}(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(x_i) = y_i)$	预测正确的样本占比，越大越好
二者关系	$\text{acc}(f; D) = 1 - E(f; D)$	互补关系


查准率和查全率

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

$$P = \frac{TP}{TP + FP}$$

$$R = \frac{TP}{TP + FN}$$

PR曲线与平衡点 (BEP) 分析




PR图分析:

- 学习器A优于学习器C
- 学习器B优于学习器C
- 学习器A优于学习器B

BEP分析:

- 学习器A优于学习器B
- 学习器A优于学习器C
- 学习器B优于学习器C

AUC: Area Under the ROC Curve



ROC (Receiver Operating Characteristic) Curve
[Green & Swets, Book 66; Spackman, IWML'89]

横轴: 反例被判为正例的比率 (False Positive Rate)
纵轴: 正例被判为正例的比率 (True Positive Rate)

The bigger, the better

$$AUC = 1 - \frac{1}{m_+ + m_-} \sum_{x^+ \in \mathcal{D}^+} \sum_{x^- \in \mathcal{D}^-} \left(\mathbb{I}(f(x^+) < f(x^-)) + \frac{1}{2} \mathbb{I}(f(x^+) = f(x^-)) \right)$$

$$tpr = \frac{TP}{TP + FN} = \frac{TP}{m_+} \quad (\text{真正例率})$$

$$fpr = \frac{FP}{FP + TN} = \frac{FP}{m_-} \quad (\text{假正例率})$$

How to do AI?

从简单到复杂：一条线 → 一条更好的边界 →
一棵树 → 多个模型 → 无标签找结构 → 高维数据先降维

任务怎么定义	监督学习、无监督学习	机器学习首先要判断：数据有没有标签。有标签时，我们关心预测；没有标签时，我们关心数据内部结构。
最基本的预测模型	线性回归、Logistic 回归	线性模型是最基础的一类方法，它假设输入特征和输出之间可以用一个线性关系描述。
复杂边界怎么处理	SVM、核函数	当线性模型不够时，SVM通过最大间隔寻找更稳定的分类边界；核函数进一步处理非线性问题。
规则型模型	决策树	决策树不是找一条边界，而是通过一系列特征判断，把样本逐步划分到不同类别。
概率型模型	朴素贝叶斯	朴素贝叶斯从概率角度出发，根据样本属于不同类别的概率大小进行分类。
单个模型不够怎么办	Bagging、Boosting、随机森林	集成学习的思想是把多个基学习器组合起来，提高模型稳定性或预测能力。
没有标签怎么办	K-means、DBSCAN、层次聚类	聚类不利用真实类别标签，而是根据样本之间的相似性，把数据自动分成若干组。
维度太高怎么办	PCA、降维	当特征维度过高时，降维希望用更少的变量保留数据中的主要信息。

信息熵

Information Entropy and Sample Purity

Entropy is a key indicator for measuring the purity of a sample set $\mathcal{D}$. Assuming p_k is the proportion of the k -th sample class in $\mathcal{D}$, Information Entropy is defined as:

$$Ent(D) = - \sum_{k=1}^{|Y|} p_k \log_2 p_k$$

Convention:

If $p=0$, then $p \log_2 p = 0$.

Minimum $Ent(D) = 0$,

Maximum $Ent(D) = \log_2 |Y|$.

The smaller the value of $Ent(D)$, the higher the purity of D .

Information gain, directly based on entropy, calculates the change caused by the current partition to information entropy.

信息增益

The value of discrete attribute a : $\{a^1, a^2, \dots, a^v\}$

D_v : The sample set of D with a value of $a = a^v$

The information gain obtained by dividing the data set D with attribute a is:

$$\text{Gain}(D, a) = \underbrace{\text{Ent}(D)}_{\text{Information entropy before partition}} - \sum_{v=1}^V \underbrace{\frac{|D^v|}{|D|}}_{\text{The weight of the } v \text{ branch: the more samples, the more important}} \underbrace{\text{Ent}(D^v)}_{\text{Information entropy after partition}}$$

**Used in ID3 Algorithm
(Iterative Dichotomiser 3)**

The weight of the v branch: the more samples, the more important

信息增益

The data set contains 17 training examples, $|y|=2$, of which positive examples account for $p_1 = \frac{8}{17}$ and negative examples account for $p_2 = \frac{9}{17}$

The information entropy of the root node is

$$\text{Ent}(D) = - \sum_{k=1}^2 p_k \log_2 p_k = - \left(\frac{8}{17} \log_2 \frac{8}{17} + \frac{9}{17} \log_2 \frac{9}{17} \right) = 0.998$$

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

信息增益

- Taking the attribute "color" as an example, the corresponding data subsets are D1 (color=cyan), D2 (color=black), D3 (color=light white)
- Subset d1 contains 6 examples numbered {1,4,6,10,13,17}, of which positive examples account for $p_1=3/6$, and negative examples account for $p_2=3/6$. The same is true for d2 and d3. The information entropy of the three nodes is

$$\text{Ent}(D^1) = -\left(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6}\right) = 1.000$$

$$\text{Ent}(D^2) = -\left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}\right) = 0.918$$

$$\text{Ent}(D^3) = -\left(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}\right) = 0.722$$

- The information gain of the attribute "color" is

$$\begin{aligned} \text{Gain}(D, \text{色泽}) &= \text{Ent}(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722\right) \\ &= 0.109 \end{aligned}$$

朴素贝叶斯分类器

下面我们用西瓜数据集 3.0 训练一个朴素贝叶斯分类器, 对测试例 “测 1” 进行分类:

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
测 1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	?

首先估计类先验概率 $P(c)$, 显然有

$$P(\text{好瓜} = \text{是}) = \frac{8}{17} \approx 0.471,$$

$$P(\text{好瓜} = \text{否}) = \frac{9}{17} \approx 0.529.$$

$$P(\text{好瓜} = \text{是}) \times P_{\text{青绿}|\text{是}} \times P_{\text{蜷缩}|\text{是}} \times P_{\text{浊响}|\text{是}} \times P_{\text{清晰}|\text{是}} \times P_{\text{凹陷}|\text{是}}$$

$$\times P_{\text{硬滑}|\text{是}} \times p_{\text{密度: 0.697}|\text{是}} \times p_{\text{含糖: 0.460}|\text{是}} \approx 0.038,$$

$$P(\text{好瓜} = \text{否}) \times P_{\text{青绿}|\text{否}} \times P_{\text{蜷缩}|\text{否}} \times P_{\text{浊响}|\text{否}} \times P_{\text{清晰}|\text{否}} \times P_{\text{凹陷}|\text{否}}$$

$$\times P_{\text{硬滑}|\text{否}} \times p_{\text{密度: 0.697}|\text{否}} \times p_{\text{含糖: 0.460}|\text{否}} \approx 6.80 \times 10^{-5}.$$

由于 $0.038 > 6.80 \times 10^{-5}$, 因此, 朴素贝叶斯分类器将测试样本 “测 1” 判别为 “好瓜”.

需注意, 若某个属性值在训练集中没有与某个类同时出现过, 则直接基于式(7.17)进行概率估计, 再根据式(7.15) 进行判别将出现问题. 例如, 在使用西瓜数据集 3.0 训练朴素贝叶斯分类器时, 对一个 “敲声=清脆” 的测试例, 有

$$P_{\text{清脆}|\text{是}} = P(\text{敲声} = \text{清脆} | \text{好瓜} = \text{是}) = \frac{0}{8} = 0,$$

然后, 为每个属性估计条件概率 $P(x_i | c)$:

$$P_{\text{青绿}|\text{是}} = P(\text{色泽} = \text{青绿} | \text{好瓜} = \text{是}) = \frac{3}{8} = 0.375,$$

$$P_{\text{青绿}|\text{否}} = P(\text{色泽} = \text{青绿} | \text{好瓜} = \text{否}) = \frac{3}{9} \approx 0.333,$$

$$P_{\text{蜷缩}|\text{是}} = P(\text{根蒂} = \text{蜷缩} | \text{好瓜} = \text{是}) = \frac{5}{8} = 0.375,$$

$$P_{\text{蜷缩}|\text{否}} = P(\text{根蒂} = \text{蜷缩} | \text{好瓜} = \text{否}) = \frac{3}{9} \approx 0.333,$$

$$P_{\text{浊响}|\text{是}} = P(\text{敲声} = \text{浊响} | \text{好瓜} = \text{是}) = \frac{6}{8} = 0.750,$$

$$P_{\text{浊响}|\text{否}} = P(\text{敲声} = \text{浊响} | \text{好瓜} = \text{否}) = \frac{4}{9} \approx 0.444,$$

$$P_{\text{清晰}|\text{是}} = P(\text{纹理} = \text{清晰} | \text{好瓜} = \text{是}) = \frac{7}{8} = 0.875,$$

$$P_{\text{清晰}|\text{否}} = P(\text{纹理} = \text{清晰} | \text{好瓜} = \text{否}) = \frac{2}{9} \approx 0.222,$$

$$P_{\text{凹陷}|\text{是}} = P(\text{脐部} = \text{凹陷} | \text{好瓜} = \text{是}) = \frac{6}{8} = 0.750,$$

$$P_{\text{凹陷}|\text{否}} = P(\text{脐部} = \text{凹陷} | \text{好瓜} = \text{否}) = \frac{2}{9} \approx 0.222,$$

$$P_{\text{硬滑}|\text{是}} = P(\text{触感} = \text{硬滑} | \text{好瓜} = \text{是}) = \frac{6}{8} = 0.750,$$

$$P_{\text{硬滑}|\text{否}} = P(\text{触感} = \text{硬滑} | \text{好瓜} = \text{否}) = \frac{6}{9} \approx 0.667,$$

$$p_{\text{密度: 0.697}|\text{是}} = p(\text{密度} = 0.697 | \text{好瓜} = \text{是})$$

$$= \frac{1}{\sqrt{2\pi} \cdot 0.129} \exp\left(-\frac{(0.697 - 0.574)^2}{2 \cdot 0.129^2}\right) \approx 1.959,$$

$$p_{\text{密度: 0.697}|\text{否}} = p(\text{密度} = 0.697 | \text{好瓜} = \text{否})$$

$$= \frac{1}{\sqrt{2\pi} \cdot 0.195} \exp\left(-\frac{(0.697 - 0.496)^2}{2 \cdot 0.195^2}\right) \approx 1.203,$$

$$p_{\text{含糖: 0.460}|\text{是}} = p(\text{含糖率} = 0.460 | \text{好瓜} = \text{是})$$

$$= \frac{1}{\sqrt{2\pi} \cdot 0.101} \exp\left(-\frac{(0.460 - 0.279)^2}{2 \cdot 0.101^2}\right) \approx 0.788,$$

$$p_{\text{含糖: 0.460}|\text{否}} = p(\text{含糖率} = 0.460 | \text{好瓜} = \text{否})$$


$$= \frac{1}{\sqrt{2\pi} \cdot 0.108} \exp\left(-\frac{(0.460 - 0.154)^2}{2 \cdot 0.108^2}\right) \approx 0.066.$$

集成学习


特征	Bagging	Boosting
 核心思想	并行训练多个弱分类器，然后投票（平均）组合	顺序训练多个弱分类器，后一个模型纠正前一个模型的错误
 样本选取方式	有放回随机采样 (Bootstrap)，每轮选不同样本子集	每轮根据前一轮的错误样本 调整权重，关注“难分类”样本
 训练方式	并行训练多个分类器，互不影响	串行逐步训练，每一轮依赖前一轮的结果
 主要目标	减少模型的 方差 (variance) 防止过拟合	减少模型的 偏差 (bias) 提升预测能力
 关注重点	所有样本都“平均对待”	对错误分类样本 加大关注
 常见基学习器	决策树（如 CART），可用高方差模型	决策树（浅层 stump），适用于弱学习器
 典型代表	Random Forest	AdaBoost, Gradient Boosting, XGBoost
 对异常值的敏感性	不太敏感（因为投票平滑了误差）	较敏感（错误点被反复强调）
 可并行性	✅ 高，可并行加速	❌ 串行依赖，难以并行化

How to do AI?


Illustration of K-means:




(a)




(b)




(c)



(d)



(e)



(f)

How to do AI?

DBSCAN

工作流程:

参数D: 输入数据集


参数eps: 指定半径

可以根据K距离来设定: 找到突变点

K距离: 给定数据集 $P=\{p(i); i=0,1,..n\}$, 计算点 $P(i)$ 到数据D的子集S中所有点之间的距离, 按照从小到大顺序排序, $d(k)$ 就被称为k-距离

MinPts: 密度阈值

k-距离中的k值, 一般取的小一些, 多次尝试



输入:

D: 一个包含 n 个对象的数据集

ϵ : 半径参数

MinPts: 领域密度阈值

输出: 基于密度的簇的集合

方法:

1. 标记所有对象为 unvisited;
2. Do
3. 随机选择一个 unvisited 对象 p ;
4. 标记 p 为 visited;
5. If p 的 ϵ -领域至少有 MinPts 个对象
6. 创建一个新簇 C , 并把 p 添加到 C ;
7. 令 N 为 p 的 ϵ -领域 中的对象集合
8. For N 中每个点 p'
9. If p' 是 unvisited;
10. 标记 p' 为 visited;
11. If p' 的 ϵ -领域至少有 MinPts 个对象, 把这些对象添加到 N ;
12. 如果 p' 还不是任何簇的成员, 把 p' 添加到 C ;
13. End for;
14. 输出 C ;
15. Else 标记 p 为噪声;
16. Until 没有标记为 unvisited 的对象;

https://blog.csdn.net/qq_39293290

核心问题	对应内容	最重要的理解
数据有没有标签？	监督学习 / 无监督学习	有标签做预测；无标签找结构
训练集好是否等于模型好？	经验误差 / 泛化误差	真正关心的是新数据上的表现
怎么评价分类结果？	混淆矩阵、Precision、Recall、F1	不同指标关注不同错误类型
最基础的模型是什么？	线性模型、Logistic 回归	用线性关系或线性边界描述数据
边界怎么更稳？	SVM	找最大间隔分类边界，核函数处理非线性
怎么用规则分类？	决策树	通过一系列特征判断逐步划分样本
怎么用概率分类？	朴素贝叶斯	根据先验和条件概率推断类别
一个模型不够怎么办？	集成学习	多个模型组合，提高稳定性或预测能力
Bagging 和 Boosting 差在哪？	随机森林 / AdaBoost	Bagging 降方差，Boosting 降偏差
没有标签怎么分组？	K-means、DBSCAN、层次聚类	根据相似性发现数据内部结构
维度太高怎么办？	PCA、降维	保留主要信息，去掉冗余和噪声
贯穿全课的主线是什么？	任务、数据、模型假设、泛化	根据问题选择合适模型，而不是机械套算法