

Artificial Intelligence for Science



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY



地球与空间科学系
DEPARTMENT OF EARTH AND SPACE SCIENCES

Lesson 12: Convolutional Neural Network (卷积神经网络)


CHEN Kejie 陈克杰 (chenkj@sustech.edu.cn)

29-Apr-26




全连接前馈神经网络 (FCNN)

▶ 权重矩阵的参数非常多



▶ 局部不变性特征

- ▶ 自然图像中的物体都具有局部不变性特征
 - ▶ 尺度缩放、平移、旋转等操作不影响其语义信息。
- ▶ 全连接前馈网络很难提取这些局部不变特征



28*28的图像

输入层 (784) → 隐藏层1 (128)

权重数: $784 \times 128 = 100,352$

偏置项: 128

小计: **100,480** 个参数

隐藏层1 (128) → 隐藏层2 (64)

• 权重数: $128 \times 64 = 8,192$

• 偏置项: 64

• 小计: **8,256** 个参数

隐藏层2 (64) → 输出层 (10)

• 权重数: $64 \times 10 = 640$

• 偏置项: 10

• 小计: **650** 个参数

$100,480 + 8,256 + 650$
 $= 109,386$ 个参数

卷积神经网络

- ▶ **卷积神经网络 (Convolutional Neural Networks, CNN)**
 - ▶ 一种前馈神经网络
 - ▶ 受生物学上感受野 (Receptive Field) 的机制而提出的
 - ▶ 在视觉神经系统中，一个神经元的**感受野**是指视网膜上的特定区域，只有这个区域内的刺激才能够激活该神经元 (1981年David和Torsten诺贝尔奖)。
- ▶ **卷积神经网络有三个结构上的特性：**
 - ▶ 局部连接 (local connection)
 - ▶ 权重共享 (weight sharing)
 - ▶ 空间或时间上的次采样 (sub-sampling)

卷积 (Convolution)

- ▶ 卷积经常用在信号处理中，用于计算信号的延迟累积。
- ▶ 假设一个信号发生器每个时刻 t 产生一个信号 x_t ，其信息的衰减率为 w_k ，即在 $k-1$ 个时间步长后，信息为原来的 w_k 倍
 - ▶ 假设 $w_1 = 1, w_2 = 1/2, w_3 = 1/4$
- ▶ 时刻 t 收到的信号 y_t 为当前时刻产生的信息和以前时刻延迟信息的叠加。

卷积 (Convolution)

- ▶ 卷积经常用在信号处理中，用于计算信号的延迟累积。
- ▶ 假设一个信号发生器每个时刻 t 产生一个信号 x_t ，其信息的衰减率为 w_k ，即在 $k-1$ 个时间步长后，信息为原来的 w_k 倍
 - ▶ 假设 $w_1 = 1, w_2 = 1/2, w_3 = 1/4$
- ▶ 时刻 t 收到的信号 y_t 为当前时刻产生的信息和以前时刻延迟信息的叠加

$$\begin{aligned} y_t &= 1 \times x_t + 1/2 \times x_{t-1} + 1/4 \times x_{t-2} \\ &= w_1 \times x_t + w_2 \times x_{t-1} + w_3 \times x_{t-2} \\ &= \sum_{k=1}^3 w_k \cdot x_{t-k+1} \end{aligned}$$


滤波器 (filter) 或卷积核 (convolution kernel)

卷积 (Convolution)

- 给定一个输入信号序列 x 和滤波器 w ,卷积的输出为:


$$y_t = \sum_{k=1}^K w_k x_{t-k+1}$$

Filter: [-1,0,1]




卷积 (Convolution)

► 不同的滤波器来提取信号序列中的不同特征



(a) 滤波器 $[1/3, 1/3, 1/3]$

低频信息



(b) 滤波器 $[1, -2, 1]$


高频信息

$$y''(u) = y(u + 1) + y(u - 1) - 2y(u)$$


二阶微分

卷积扩展 (Convolution Extension)

► 引入滤波器的滑动步长 *Stride* 和零填充 *Padding*



(a) 步长 $S = 2$



(b) 零填充 $P = 1$

Filter: $[-1, 0, 1]$

卷积类型

► 卷积的结果按输出长度不同可以分为三类：

- 窄卷积：步长 $T=1$ ，两端不补零 $P=0$ ，卷积后输出长度为 $M-K+1$
- 宽卷积：步长 $T=1$ ，两端补零 $P=K-1$ ，卷积后输出长度 $M+K-1$
- 等宽卷积：步长 $T=1$ ，两端补零 $P=(K-1)/2$ ，卷积后输出长度 M

M 为神经元个数、 K 为卷积大小

- 在早期的文献中，卷积一般默认为窄卷积。
- 而目前的文献中，卷积一般默认为等宽卷积。

二维卷积

- 在图像处理中，图像是以二维矩阵的形式输入到神经网络中，因此我们需要二维卷积。

一个输入信息 $\mathbf{X}$ 和滤波器 $\mathbf{W}$ 的二维卷积定义为

$$\mathbf{Y} = \mathbf{W} * \mathbf{X},$$

$$y_{ij} = \sum_{u=1}^U \sum_{v=1}^V w_{uv} x_{i-u+1, j-v+1}.$$


1	1	1	1	1
-1	0	-3	0	1
2	1	1	-1	0
0	-1	1	2	1
1	2	1	1	1

$*$

1	0	0
0	0	0
0	0	-1

$=$

0	-2	-1
2	2	4
-1	0	0



卷积作为特征提取器

$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{16}$
$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{8}$
$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{16}$

=




高斯滤波去噪



$\otimes$

0	1	0
1	-4	1
0	1	0

=




平均滤波提高频

原始图像

0	1	1
-1	0	1
-1	-1	0

=




滤波器


特定方向

输出特征映射


二维卷积




步长1，零填充0



步长2，零填充0




步长1，零填充1




步长2，零填充1

卷积神经网络

► 用卷积层代替全连接层



(a) 全连接层



(b) 卷积层

互相关 (Cross-Correlation)

- ▶ 计算卷积需要进行卷积核翻转。
- ▶ 卷积操作的目标：提取特征。

翻转是不必要的！

▶ 互相关

$$y_{ij} = \sum_{u=1}^m \sum_{v=1}^n w_{uv} \cdot x_{i+u-1, j+v-1}$$

除非特别声明，卷积一般指“互相关”。

多个卷积核

▶ 特征映射 (Feature Map) : 图像经过卷积后得到的特征。


▶ 卷积核看成一个特征提取器, 卷积核的个数为新的特征空间个数

▶ 卷积层

▶ 输入: D 个特征映射 $M \times N \times D$


▶ 输出: P 个特征映射 $M' \times N' \times P$

卷积层的映射关系



$$Z^p = W^p \otimes X + b^p = \sum_{d=1}^D W^{p,d} \otimes X^d + b^p,$$

$$Y^p = f(Z^p).$$



步长2

filter 3*3

filter个数6

零填充 1


其中，Output Volume中的 $o[:, :, 0]$ 的输出结果1的计算方法为：

$$W0[:, :, 0] * x[:, :, 0] + W0[:, :, 1] * x[:, :, 1] + W0[:, :, 2] * x[:, :, 2] + b$$

*为卷积操作

汇聚层 (Pooling)


- 卷积层虽然可以显著减少连接的个数，但是每一个特征映射的神经元个数并没有显著减少。



汇聚层 (Pooling)

Pooling layer: Max pooling

2	3	1	9
4	7	3	5
8	2	2	2
1	3	4	5



7	9
8	5

Max-Pool with a
2 by 2 filter and
stride 2.

汇聚层 (Pooling)

Pooling layer: Average pooling

2	3	1	9
4	7	3	5
8	2	2	2
1	3	4	5



4	4.5
3.25	3.25

Average Pool with
a 2 by 2 filter and
stride 2.

除了减少神经元数量外，池化的目的还包括：


1: 提高不变性

对位移、缩放、局部扰动不敏感（保持语义），如视角略变你仍能识别猫脸

2: 提取主特征

最大池化可强化显著区域，平均池化可保留趋势，保留“最强信号”或“主要趋势”

展开(Flatten)




卷积网络结构

► 卷积网络是由卷积层、汇聚层、全连接层交叉堆叠而成。

► 趋向于小卷积、大深度


► 趋向于全卷积

► 典型结构




► 一个卷积块为连续 M 个卷积层和 b 个汇聚层（ M 通常设置为 $2 \sim 5$ ， b 为0或1）。一个卷积网络中可以堆叠 N 个连续的卷积块，然后在接着 K 个全连接层（ N 的取值区间比较大，比如 $1 \sim 100$ 或者更大； K 一般为 $0 \sim 2$ ）。



表征学习 (Feature Learning)



表征学习 (Feature Learning)



CNN in Keras



CNN in Keras


```
model2.add( Convolution2D( 25, 3, 3,  
                           input_shape=(28, 28, 1)) )
```

1	0	1
0	1	0
1	0	1


设置25个3*3的卷积核；
输入数组的大小是28*28，
1个通道；

设置的池化核的大小为2*2

```
model2.add(MaxPooling2D((2, 2)))
```



CNN in Keras



CNN in Keras

参数个数

📦 卷积层参数计算:

◆ Conv1:

- 输入通道: 1
- 卷积核数量: 25
- 卷积核大小: 3×3 (推测)
- 参数数:

$$25 \times (3 \times 3 \times 1 + 1) = 25 \times 10 = 250$$

(含 bias)

◆ Conv2:

- 输入通道: 25
- 卷积核数量: 50
- 卷积核大小: 3×3
- 参数数:

$$50 \times (3 \times 3 \times 25 + 1) = 50 \times (225 + 1) = 50 \times 226 = 11,300$$

✅ 卷积层参数合计:

$$250 + 11,300 = 11,550$$

📦 全连接层 (Dense) 参数计算:

Flatten 后为 $50 \times 5 \times 5 = 1250$ 个输入节点

◆ Dense1:

- 输入维度: 1250
- 输出维度: 100
- 参数数:

$$1250 \times 100 + 100 = 125,000 + 100 = 125,100$$

◆ Dense2 (输出层):

- 输入维度: 100
- 输出维度: 10 (比如 MNIST 10 类)
- 参数数:

$$100 \times 10 + 10 = 1000 + 10 = 1010$$

✅ 全连接层参数合计:


$$125,100 + 1010 = 126,110$$

$$\text{总参数} = 11,550 \text{ (卷积)} + 126,110 \text{ (全连接)} = 137,660$$


典型的卷积网络

LeNet-5

- ▶ LeNet-5 是一个非常成功的神经网络模型。
- ▶ 基于 LeNet-5 的手写数字识别系统在 90 年代被美国很多银行使用，用来识别支票上面的手写数字。
- ▶ LeNet-5 共有 7 层。



Connection table for C3 layer in LeNet-5




连接表，减少参数

AlexNet

► 2012 ILSVRC winner

- (top 5 error of 16% compared to runner-up with 26% error)
- 第一个现代深度卷积网络模型
 - 首次使用了很多现代深度卷积网络的一些技术方法
 - 使用GPU进行并行训练，采用了ReLU作为非线性激活函数，使用Dropout防止过拟合，使用数据增强
- 5个卷积层、3个汇聚层和3个全连接层

~60M 参数



Large Scale Visual Recognition Challenge


2012 Teams	%error	2013 Teams	%error	2014 Teams	%error
Supervision (Toronto)	15.3	Clarifai (NYU spinoff)	11.7	GoogLeNet	6.6
ISI (Tokyo)	26.1	NUS (singapore)	12.9	VGG (Oxford)	7.3
VGG (Oxford)	26.9	Zeiler-Fergus (NYU)	13.5	MSRA	8.0
XRCE/INRIA	27.0	A. Howard	13.5	A. Howard	8.1
UvA (Amsterdam)	29.6	OverFeat (NYU)	14.1	DeeperVision	9.5
INRIA/LEAR	33.4	UvA (Amsterdam)	14.2	NUS-BST	9.7
		Adobe	15.2	TTIC-ECP	10.2
		VGG (Oxford)	15.2	XYZ	11.2
		VGG (Oxford)	23.0	UvA	12.1



Inception网络


► 2014 ILSVRC winner (22层)

- 参数: GoogLeNet: 4M VS AlexNet: 60M
- 错误率: 6.7%
- Inception网络是由有多个inception模块和少量的汇聚层堆叠而成。



Inception模块 v1

- ▶ 在卷积网络中，如何设置卷积层的卷积核大小是一个十分关键的问题。
- ▶ 在Inception网络中，一个卷积层包含多个不同大小的卷积操作，称为Inception模块。
- ▶ Inception模块同时使用 1×1 、 3×3 、 5×5 等不同大小的卷积核，并将得到的特征映射在深度上拼接（堆叠）起来作为输出特征映射。



1×1 卷积核不是“一个数字”，而是一个“通道方向的滤波器”。它对每个像素点的所有通道做加权组合，是“通道融合”的核心操作

Inception模块 v3

- ▶ 用多层的小卷积核来替换大的卷积核，以减少计算量和参数量。
- ▶ 使用两层 3×3 的卷积来替换v1中的 5×5 的卷积
- ▶ 使用连续的 $n \times 1$ 和 $1 \times n$ 来替换 $n \times n$ 的卷积。




Figure 5. Inception modules where each 5×5 convolution is replaced by two 3×3 convolution, as suggested by principle 3 of Section 2

<http://blog.csdn.net/xbinworld>





Figure 6. Inception modules after the factorization of the $n \times n$ convolutions. In our proposed architecture, we chose $n = 7$ for the 17×17 grid. (The filter sizes are picked using principle 3)

<http://blog.csdn.net/xbinworld>

ResNet

- ▶ 2015 ILSVRC winner (152层)
- ▶ 错误率: 3.57%



残差网络 (Residual Network)

- ▶ 残差网络 (Residual Network, ResNet) 是通过给非线性的卷积层增加直连边的方式来提高信息的传播效率。
- ▶ 假设在一个深度网络中，我们期望一个非线性单元（可以为一层或多层的卷积层） $f(x, \theta)$ 去逼近一个目标函数为 $h(x)$ 。
- ▶ 将目标函数拆分成两部分：恒等函数和残差函数

$$h(x) = \underbrace{x}_{\text{恒等函数}} + \underbrace{(h(x) - x)}_{\text{残差函数}} = f(x, \theta)$$



Kaiming He
Associate Professor, EECS, MIT
Verified email at mit.edu - [Homepage](#)
Computer Vision Machine Learning

TOP TEN MOST-CITED WORKS OF THE TWENTY-FIRST CENTURY		
Rank (median)	Citation	Times cited (range across databases)
1	Deep residual learning for image recognition (2016, preprint 2015)	103,756-254,074
2	Analysis of relative gene expression data using real-time quantitative PCR and the 2 ^{-ΔΔC_T} method (2001)	149,953-185,480
3	Using thematic analysis in psychology (2006)	100,327-230,391
4	Diagnostic and Statistical Manual of Mental Disorders, DSM-5 (2013)	98,312-367,800
5	A short history of SHELX (2007)	76,523-99,470
6	Random forests (2001)	31,809-146,508
7	Attention is all you need (2017)	56,201-150,832
8	ImageNet classification with deep convolutional neural networks (2017)	46,860-137,997
9	Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries (2020)	75,634-99,390
10	Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries (2016)	66,844-93,433

Source databases: Web of Science, Scopus, OpenAlex, Dimensions, Google Scholar.
For a list of the top 25 most-cited works, see Supplementary information (go.nature.com/4tsgtdj).



何恺明



TITLE	CITED BY
Deep Residual Learning for Image Recognition K He, X Zhang, S Ren, J Sun Computer Vision and Pattern Recognition (CVPR), 2016	272323

21世纪引用
最多的文章

残差单元

基础残差块
(Basic Block)


这是 ResNet-18 / 34
中使用的标准结构：
两个卷积层，通道数不变
不需要维度转换




瓶颈残差块
(Bottleneck Block)

这是 ResNet-50 /
101 / 152 使用的
结构

减小计算量，同时
加深网络




提取新特征（比如细节、边缘增强）



这个 $f(x)$ 就是“模型要学的新内容”，也就是残差！

卷积的应用

AlphaGo



The input to the policy network is a $19 \times 19 \times 48$ image stack consisting of 48 feature planes. The first hidden layer zero pads the input into a 23×23 image, then convolves k filters of kernel size 5×5 with stride 1 with the input image and applies a rectifier nonlinearity. Each of the subsequent hidden layers 2 to 12 zero pads the respective previous hidden layer into a 21×21 image, then convolves k filters of kernel size 3×3 with stride 1, again followed by a rectifier nonlinearity. The final layer convolves 1 filter of kernel size 1×1 with stride 1, with a different bias for each position, and applies a softmax function. The match version of AlphaGo used $k = 192$ filters; Fig. 2b and Extended Data Table 3 additionally show the results of training with $k = 128, 256$ and 384 filters.

policy network:

[19x19x48] Input


CONV1: 192 5x5 filters, stride 1, pad 2 => [19x19x192]

CONV2..12: 192 3x3 filters, stride 1, pad 1 => [19x19x192]

CONV: 1 1x1 filter, stride 1, pad 0 => [19x19] (*probability map of promising moves*)

- ▶ 分布式系统：1202 个CPU 和176 块GPU
- ▶ 单机版：48 个CPU 和8 块GPU
- ▶ 走子速度：3 毫秒-2 微秒

目标检测 (Object Detection)



OCR (Optical Character Recognition, 光学字符识别)



课后作业

编程练习

